中山大学数据科学与计算机院本科生实验报告

(2020 学年秋季学期)

课程名称：**高性能计算程序设计**　　任课教师：**黄聃**　　**批改人：**

年级+班级	2018 级五班	专业（方向）	计算机科学与技术
学号	18340126	姓名	罗仁良
Email	luorliang@mail2.sysu.edu.cn	完成日期	2020 年 12 月 18 日

1. 实验目的

1.1　使用 CUDA 实现通用矩阵乘法

1.2　基于 OpenMP+CUDA 的多层次并行，实现通用矩阵乘法

1.3　调用 CUBLAS 计算矩阵相乘，比较分析不同方法的性能。

2. 实验过程和核心代码

2.1 CUDA 实现通用矩阵乘法

实现的基本思路是，一个线程计算矩阵 C 的一个元素。在使用二维 Blcok 的情况下，比较容易得到矩阵元素与线程的对应关系。对应关系如图一所示。

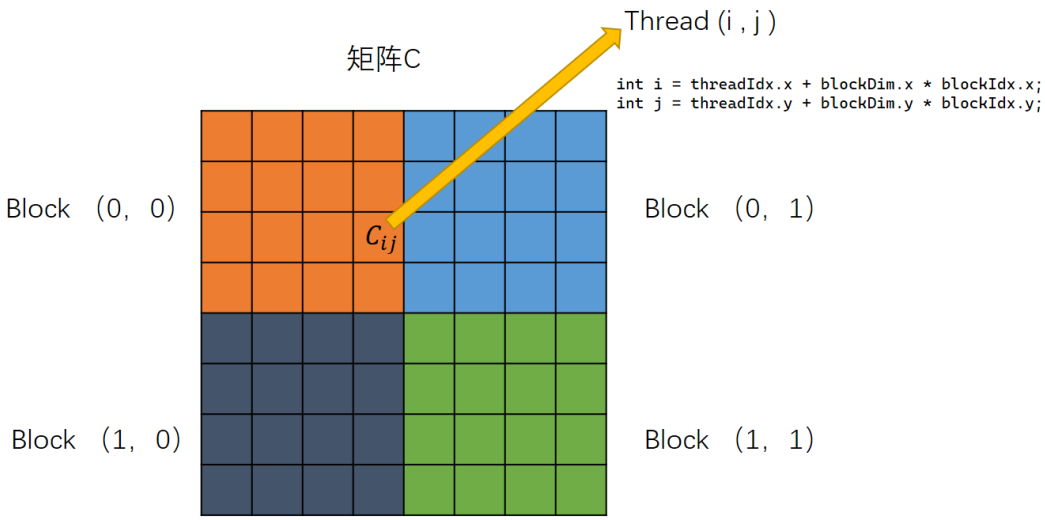

图一：线程索引与矩阵元素的对应关系

2.1.1 Grid 和 Block 划分

Grid 和 Blcok 都是使用二维划分的形式，与二维矩阵相契合。

```
dim3 Block(blocksize, blocksize);
dim3 Grid((m+Block.x-1)/ Block.x, (k+Block.y-1)/ Block.y );
```

2.1.2 Kernel 函数

Kernel 函数是一个线程完成的计算任务，也就是矩阵 C 一个元素的计算。需要的参数除了矩阵 A、B、C 之外，还需要传入矩阵 A 和矩阵 B 的列的维数。

因为为了减少数据传输的次数，矩阵都是采用一维数组保存，需要矩阵的维度信息，实现对任意元素访问。

```
__global__ void matrix_mul_gpu(float *A, float * B, float * C, int col_a, int col_b)
{
    // 由线程索引确定计算 Cij
    int i = threadIdx.x + blockDim.x * blockIdx.x;
    int j = threadIdx.y + blockDim.y * blockIdx.y;

    int sum = 0;
    for(int k=0;k<col_a;k++)
    {
        sum += A[i*col_a+k]*B[k*col_b+j];
    }
    C[i*col_b+j] = sum; // Cij = sum;
}
```

2.1.3 数据传输

1）把 CPU 主存上的数据传输到 GPU 上

```
cudaMemcpy(dA, A, sizeof(float) * m * n, cudaMemcpyHostToDevice);
cudaMemcpy(dB, B, sizeof(float) * n * k, cudaMemcpyHostToDevice);
```

2）计算结果传回 CPU 的主存

```
cudaMemcpy(C, dC, sizeof(float) * m * k, cudaMemcpyDeviceToHost);
```

2.1.4 资源回收

释放在 CPU 主存和 GPU 主存申请的资源。

```
    free(A);
    free(B);
    free(C);
    cudaFree(dA);
    cudaFree(dB);
    cudaFree(dC);
```

2.2 OpenMP+CUDA 多层次并行

使用 OpenMP 把主进程切分多个并行的子线程，每个子线程调用使用 CUDA 实现的矩阵乘法函数，由此实现两个层次上的并行。一个是利用 OepnMP 的多线程的并行，另一个是使用 CUDA 实现的多线程并行。

2.2.1 线程任务划分

把矩阵 A 按行分配，每个线程计算矩阵 C 的部分行。任务划分的时候尽量保证负载均衡。

```
int q = m / num_thread;
int r = m % num_thread;
// first 矩阵 A 的起始行
// count 需要计算的行数
int first,count;
count = q;
if(rank < r) {
    count = q + 1;
    first = count * rank;
}
else {
    first = count * rank + r;
}
```

2.2.2 数据传输

根据任务划分的方式，矩阵 B 是每个子线程都共享的数据，所以把矩阵 B 传输到 GPU 上作为全局变量，减少矩阵 B 传输的次数。

```
cudaMemcpy(dB,B,sizeof(float)*n*k,cudaMemcpyHostToDevice);
```

在每个线程中，线程根据任务划分，传输矩阵 A 中自己负责计算的那部分，减少数据传输的量。

```
cudaMemcpy(dA,A+first*n,sizeof(float)*count*n,cudaMemcpyHostToDevice);
```

2.2.3 主线程并行部分

```
#pragma omp parallel num_threads(num_thread)
{    // 参数：
     // CPU 上的矩阵 A 数据
     // GPU 上的矩阵 B 数据
     // 矩阵维度 m，n，k
     // omp_get_thread_num() 子线程的 rank
     // 并行线程数量 num_thread
     // block size blocksize
    cudaMul(A,dB,C,m,n,k,omp_get_thread_num(),num_thread,blocksize);
}
```

2.3 调用 CUBLAS 计算矩阵相乘

使用 CUBLAS 的库进行矩阵乘法运算比较简单。有一个需要的注意的是，库函数中的矩阵大多以列为形式的储存。在计算的时候需要特别的转换。

```
cublasHandle_t handle;
cublasCreate(&handle);
cublasSgemm(handle,
            CUBLAS_OP_N,CUBLAS_OP_N,
            k,m,n,
            &alpha,
            dB,k,
            dA,n,
            &beta,
             dC,k);
cudaMemcpy(C, dC, sizeof(float) * m * k, cudaMemcpyDeviceToHost);
```

3. 实验结果

3.1 任务 1：CUDA 实现矩阵乘法

矩阵规模	Blcok size	时间（ms）
512	32	2.968
1024	64	7.717
2048	128	47.553
4096	256	445.213
8192	512	2782.768

3.2 任务 2：OpenMP+CUDA 实现矩阵乘法

矩阵规模	线程数量	时间（ms）
2048	1	23.613
2048	2	24.202
2048	4	75.833
2048	8	49.661

注：Block size 为 128

从结果看，不太符合预期。随着并行线程的增加，计算时间在增加。在增加到 8 个线程的时候，计算时间又下降了，结果比较奇怪。简单分析是多线程并行的时候传输数据的次数增加了，传输数据的开销，在程序运行中占的比列过大，降低了性能。

3.3 任务 3：调用 CUBLAS 实现矩阵乘法

矩阵规模	时间（ms）
512	225.983
1024	236.192
2048	260.726
4096	306.816
8192	588.315

数据规模较小时，性能较低。随着规模增大，相对性能在提升。猜测可能与库的具体实现相关，不同数据规模调用的线程数量，block 规模的划分可能都不同，都会影响改程序的性能。

3.4 性能对比

比较任务 1 和任务 3 实现,可以看到在数据规模较小的时候,任务 1 的性能高很多，随着数据规模的提升，两者见的性能差距在缩小。当矩阵规模上升到 8192 时，调用库函数的性能就明显优于自己写的 CUDA 程序。

优化方向：任务 1 中的矩阵相乘，矩阵以行形式存储，在计算的时候 cache 的命中率较低，可更改为列形式存储，提高 cache 命中率。

4. 实验感想

完成本次实验之后，熟悉了 CUDA 编程的基本方式。进一步加深了对 GPU 架构的理解，Grid、block、thread 等之间的关系。同时，对 GPU 的内存分层模式有了更多的认识和理解。